

zadani

October 20, 2024

Vítejte u prvního projektu do SUI. V rámci projektu Vás čeká několik cvičení, v nichž budete doplňovat poměrně malé fragmenty kódu (místo je vyznačeno pomocí `None` nebo `pass`). Pokud se v buňce s kódem již něco nachází, využijte/neničte to. Buňky nerušte ani nepřidávejte. Snažte se programovat hezky, ale jediná skutečně aktivně zakázaná, vyhledávaná a – i opakovaně – postihovaná technika je cyklení přes data (ať už explicitním cyklem nebo v rámci `list/dict` comprehension), tomu se vyhýbejte jako čert kříží a řešte to pomocí vhodných operací lineární algebry.

Až budete s řešením hotovi, vyexportujte ho (“Download as”) jako PDF i pythonovský skript a ty odevzdejte **pojmenované názvem týmu** (tj. loginem vedoucího). Dbejte, aby bylo v PDF všechno vidět (nezůstal kód za okrajem stránky apod.).

U všech cvičení je uveden orientační počet řádků řešení. Berte ho prosím opravdu jako orientační, pozornost mu věnujte, pouze pokud ho významně překračujete.

```
[2]: import numpy as np
import copy
import matplotlib.pyplot as plt
import scipy.stats
```

1 Přípravné práce

Prvním úkolem v tomto projektu je načíst data, s nimiž budete pracovat. Vybudujte jednoduchou třídu, která se umí zkonstruovat z cesty k negativním a pozitivním příkladům, a bude poskytovat: - pozitivní a negativní příklady (`dataset.pos`, `dataset.neg` o rozměrech $[N, 7]$) - všechny příklady a odpovídající třídy (`dataset.xs` o rozměru $[N, 7]$, `dataset.targets` o rozměru $[N]$)

K načítání dat doporučujeme využít `np.loadtxt()`. Netrapte se se zapouzdřováním a gettery, berte třídu jako Plain Old Data.

Načtěte trénovací (`{positives,negatives}.trn`), validační (`{positives,negatives}.val`) a testovací (`{positives,negatives}.tst`) dataset, pojmenujte je po řadě `train_dataset`, `val_dataset` a `test_dataset`.

(6 řádků)

```
[3]: class BinaryDataset:
    def __init__(self, positives_path, negatives_path):
        # nacisti pos a neg
        self.pos = np.loadtxt(positives_path)
        self.neg = np.loadtxt(negatives_path)
```

```

        # "stohovani" pozitivnich a negativnich
        self.xs = np.vstack((self.pos, self.neg))
        #targets jako bin hodnoty, konkatenace poctu kladnych a zapornych
↪vysledku
        self.targets = np.concatenate((np.ones(self.pos.shape[0]), np.
↪zeros(self.neg.shape[0])))
        pass

train_dataset = BinaryDataset('positives.trn', 'negatives.trn')
val_dataset = BinaryDataset('positives.val', 'negatives.val')
test_dataset = BinaryDataset('positives.tst', 'negatives.tst')

print('positives', train_dataset.pos.shape)
print('negatives', train_dataset.neg.shape)
print('xs', train_dataset.xs.shape)
print('targets', train_dataset.targets.shape)

```

```

positives (2280, 7)
negatives (6841, 7)
xs (9121, 7)
targets (9121,)

```

V řadě následujících cvičení budete pracovat s jedním konkrétním příznakem. Naimplementujte proto funkci, která vykreslí histogram rozložení pozitivních a negativních příkladů z jedné sady. Nezapomeňte na legendu, ať je v grafu jasné, které jsou které. Funkci zavoláte dvakrát, vykreslete histogram příznaku 5 – tzn. šestého ze sedmi – pro trénovací a validační data

(5 řádků)


```


[4]: FOI = 5 # Feature Of Interest

def plot_data(poss, negs):
    #positives
    plt.hist(poss, label="Pozitivni", color="green", alpha=0.
↪7, edgecolor='black', linewidth=0.6)
    #negatives
    plt.hist(negs, label="Negativni", color="red", alpha=0.
↪7, edgecolor='black', linewidth=0.6)
    plt.xlabel('Hodnota')
    plt.ylabel('Cetnost')
    plt.legend()
    plt.show()
    pass

plot_data(train_dataset.pos[:, FOI], train_dataset.neg[:, FOI])
plot_data(val_dataset.pos[:, FOI], val_dataset.neg[:, FOI])

```





1.0.1 Evaluace klasifikátorů

Než přistoupíte k tvorbě jednotlivých klasifikátorů, vytvořte funkci pro jejich vyhodnocování. Nechť se jmenuje `evaluate` a přijímá po řadě klasifikátor, pole dat (o rozměrech $[N, F]$) a pole tříd ($[N]$). Jejím výstupem bude *přesnost* (accuracy), tzn. podíl správně klasifikovaných příkladů.

Předpokládejte, že klasifikátor poskytuje metodu `.prob_class_1(data)`, která vrací pole posteriorních pravděpodobností třídy 1 pro daná data. Evaluační funkce bude muset provést tvrdé prahování (na hodnotě 0.5) těchto pravděpodobností a srovnání získaných rozhodnutí s referenčními třídami. Využijte fakt, že `numpy`ovská pole lze mj. porovnávat se skalárem.

(3 řádky)

```
[5]: def evaluate(classifier, inputs, targets):
    post_prob_array = classifier.prob_class_1(inputs)
    # prahovani
    threshold = post_prob_array > 0.5
    return np.mean(threshold == targets) #array s hodnotami evaluace
    ↪ zprumerovany pro uspesnost

class Dummy:
```

```
def prob_class_1(self, xs):
    return np.asarray([0.2, 0.7, 0.7])

print(evaluate(Dummy(), None, np.asarray([0, 0, 1]))) # should be 0.66
```

0.6666666666666666

1.0.2 Baseline

Vytvořte klasifikátor, který ignoruje vstupní data. Jenom v konstruktoru dostane třídu, kterou má dávat jako tip pro libovolný vstup. Nezapomeňte, že jeho metoda `.prob_class_1(data)` musí vrátit pole správné velikosti.

(4 řádky)

```
[6]: class PriorClassifier:
    def __init__(self, class1):
        self.class1 = class1
    def prob_class_1(self, inputs):
        #naplneni pole hodnotami
        return np.full(inputs.shape, self.class1)
    pass

baseline = PriorClassifier(0)
val_acc = evaluate(baseline, val_dataset.xs[:, FOI], val_dataset.targets)
print('Baseline val acc:', val_acc)
```

Baseline val acc: 0.75

2 Generativní klasifikátory

V této části vytvoříte dva generativní klasifikátory, oba založené na Gaussovu rozložení pravděpodobnosti.

Začněte implementací funce, která pro daná 1-D data vrátí Maximum Likelihood odhad střední hodnoty a směrodatné odchylky Gaussova rozložení, které data modeluje. Funkci využijte pro natrénování dvou modelů: pozitivních a negativních příkladů. Získané parametry – tzn. střední hodnoty a směrodatné odchylky – vypíšte.

(1 řádek)

```
[7]: def mle_gauss_1d(data):
    #tvar gaussovky urcen stredni hodnotou a smerodatnou odchylkou
    return np.mean(data), np.std(data)

mu_pos, std_pos = mle_gauss_1d(train_dataset.pos[:, FOI])
mu_neg, std_neg = mle_gauss_1d(train_dataset.neg[:, FOI])

print('Pos mean: {:.2f} std: {:.2f}'.format(mu_pos, std_pos))
print('Neg mean: {:.2f} std: {:.2f}'.format(mu_neg, std_neg))
```

Pos mean: 0.48 std: 0.13

Neg mean: 0.17 std: 0.18

Ze získaných parametrů vytvořte `scipy`ovská gaussovská rozložení `scipy.stats.norm`. S využitím jejich metody `.pdf()` vytvořte graf, v němž srovnáte skutečné a modelové rozložení pozitivních a negativních příkladů. Rozsah x-ové osy volte od -0.5 do 1.5 (využijte `np.linspace`) a u volání `plt.hist()` nezapomeňte nastavit `density=True`, aby byl histogram normalizovaný a dal se srovnávat s modelem.

(2 + 8 řádků)

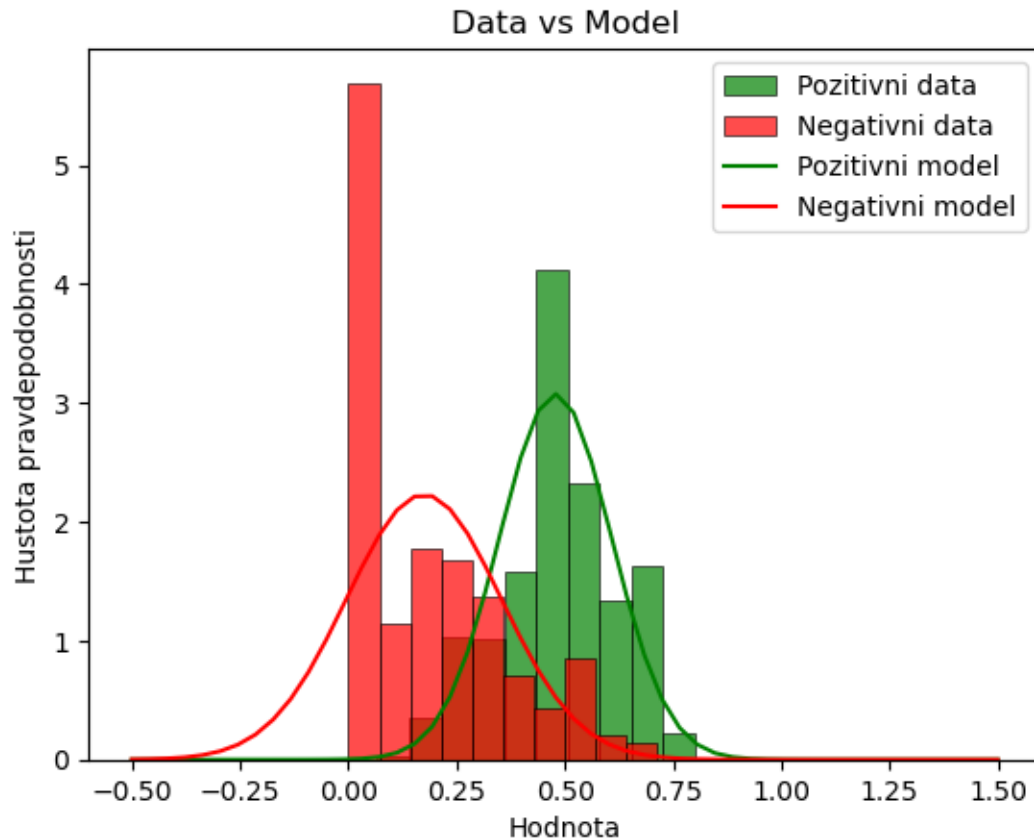
```
[8]: pos = scipy.stats.norm(loc=mu_pos, scale=std_pos)
neg = scipy.stats.norm(loc=mu_neg, scale=std_neg)

x_axis = np.linspace(-0.5, 1.5)
plt.hist(val_dataset.pos[:, FOI], density=True, color='green', alpha=0.7,
        edgecolor='black', linewidth=0.6, label='Pozitivni data')
plt.hist(val_dataset.neg[:, FOI], density=True, color='red', alpha=0.7,
        edgecolor='black', linewidth=0.6, label='Negativni data')

plt.plot(x_axis, pos.pdf(x_axis), label='Pozitivni model', color='green')
plt.plot(x_axis, neg.pdf(x_axis), label='Negativni model', color='red')

plt.title('Data vs Model')
plt.xlabel(f'Hodnota')
plt.ylabel('Hustota pravdepodobnosti')
plt.legend()

plt.show()
```



Naimplementujte binární generativní klasifikátor. Při konstrukci přijímá dvě rozložení poskytující metodu `.pdf()` a odpovídající apriorní pravděpodobnosti tříd. Dbejte, aby Vám uživatel nemohl zadat neplatné apriorní pravděpodobnosti. Jako všechny klasifikátory v tomto projektu poskytuje metodu `prob_class_1()`.

(9 řádků)

```
[9]: class GenerativeClassifier2Class:
    def __init__(self, dist1, dist0, aprior1, aprior0) -> None:
        #kontrola validity vstupu
        if aprior1 + aprior0 != 1 or aprior1 < 0 or aprior0 < 0 or aprior0 +
        ↪aprior1 < 0:
            raise ValueError
        self.aprior1 = aprior1 #pozitivni priklady
        self.aprior0 = aprior0 #negativni priklady
        self.dist1 = dist1
        self.dist0 = dist0
        pass

    def prob_class_1(self, xs):
        #rozlozeni pravdepodobnosti jednotlivych trid
```

```

        p_1 = self.dist1.pdf(xs)
        p_0 = self.dist0.pdf(xs)
        # bayesuv vzorec
        return (p_1 * self.aprior1) / ((p_1 * self.aprior1) + (p_0 * self.
↪aprior0))

    pass

```

Nainstancujte dva generativní klasifikátory: jeden s rovnoměrnými priory a jeden s apriorní pravděpodobností 0.75 pro třídu 0 (negativní příklady). Pomocí funkce `evaluate()` vyhodnotíte jejich úspěšnost na validačních datech.

(2 řádky)

```

[10]: classifier_flat_prior = GenerativeClassifier2Class(pos,neg,0.5,0.5)
      classifier_full_prior = GenerativeClassifier2Class(pos,neg,0.25,0.75)

      print('flat:', evaluate(classifier_flat_prior, val_dataset.xs[:, FOI],
↪val_dataset.targets))
      print('full:', evaluate(classifier_full_prior, val_dataset.xs[:, FOI],
↪val_dataset.targets))

```

flat: 0.809

full: 0.8475

Vykreslete průběh posteriorní pravděpodobnosti třídy 1 jako funkci příznaku 5, opět v rozsahu `<-0.5; 1.5>` pro oba klasifikátory. Do grafu zakreslete i histogramy rozložení trénovacích dat, opět s `density=True` pro zachování dynamického rozsahu.

(8 řádků)

```

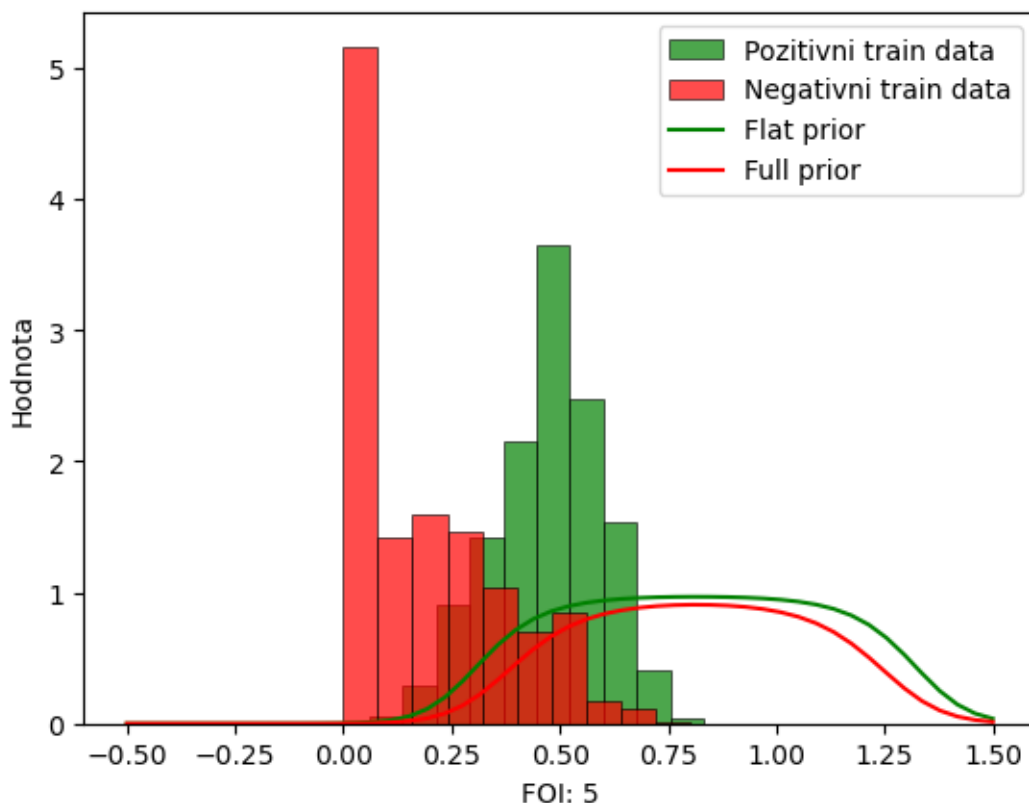
[11]: plt.hist(train_dataset.pos[:, FOI], density=True, color='green', alpha=0.7,
↪edgecolor='black', linewidth=0.6, label='Pozitivni train data')
      plt.hist(train_dataset.neg[:, FOI], density=True, color='red', alpha=0.7,
↪edgecolor='black', linewidth=0.6, label='Negativni train data')

      plt.plot(x_axis, classifier_flat_prior.prob_class_1(x_axis), label='Flat
↪prior', color='green')
      plt.plot(x_axis, classifier_full_prior.prob_class_1(x_axis), label='Full
↪prior', color='red')

      plt.xlabel(f'FOI: {FOI}')
      plt.ylabel('Hodnota')
      plt.legend()

      plt.show()
      pass

```

3 Diskriminativní klasifikátory

V následující části budete pomocí (lineární) logistické regrese přímo modelovat posteriorní pravděpodobnost třídy 1. Modely budou založeny čistě na NumPy, takže nemusíte instalovat nic dalšího. Nabitějších toolkitů se dočkáte ve třetím projektu.

```
[81]: def logistic_sigmoid(x):
    return np.exp(-np.logaddexp(0, -x))

def binary_cross_entropy(probs, targets):
    return np.sum(-targets * np.log(probs) - (1-targets)*np.log(1-probs))

class LogisticRegressionNumpy:
    def __init__(self, dim):
        self.w = np.array([0.0] * dim)
        self.b = np.array([0.0])

    def prob_class_1(self, x):
        return logistic_sigmoid(x @ self.w + self.b)
```

Diskriminativní klasifikátor očekává, že dostane vstup ve tvaru $[N, F]$. Pro práci na jediném příz-

naku bude tedy zapotřebí vyřezávat příslušná data v správném formátu ($[N, 1]$). Doimplementujte třídu `FeatureCutter` tak, aby to zařizovalo volání její instance. Který příznak se použije, necht' je konfigurováno při konstrukci.

Může se Vám hodit `np.newaxis`.

(2 řádky)

```
[45]: class FeatureCutter:
    def __init__(self, fea_id):
        self.fea_id = fea_id
        pass

    def __call__(self, x):
        return x[:,self.fea_id,np.newaxis]
```

Dalším krokem je implementovat funkci, která model vytvoří a natrénuje. Jejím výstupem bude (1) natrénovaný model, (2) průběh trénovací loss a (3) průběh validační přesnosti. Neuvažujte žádné minibatche, aktualizujte váhy vždy na celém trénovacím datasetu. Po každém kroku vyhodnoťte model na validačních datech. Jako model vracejte ten, který dosáhne nejlepší validační přesnosti. Jako loss použijte binární cross-entropii a logujte průměr na vzorek. Pro výpočet validační přesnosti využijte funkci `evaluate()`. Oba průběhy vracejte jako obvyčejné seznamy.

(cca 11 řádků)

```
[85]: def train_logistic_regression(nb_epochs, lr, in_dim, fea_preprocessor):
    model = LogisticRegressionNumpy(in_dim)
    best_model = copy.deepcopy(model)
    losses = []
    accuracies = []

    train_X = fea_preprocessor(train_dataset.xs)
    train_t = train_dataset.targets
    best_acc = 0
    for _ in range(nb_epochs):
        y = model.prob_class_1(train_X)
        #trenovaci loss
        loss = (binary_cross_entropy(y,train_t)) / len(train_t)
        losses.append(loss)
        #trenink regrese
        model.w = model.w - lr * (y-train_t).dot(train_X)
        model.b = model.b - lr * np.sum(y - train_t)

        # validacni presnost
        val_X = fea_preprocessor(val_dataset.xs)
        val_acc = evaluate(model, val_X, val_dataset.targets)
        accuracies.append(val_acc)
```

```

        # aktualizace modelu
        if val_acc > best_acc:
            best_acc = val_acc
            best_model = copy.deepcopy(model)

    return best_model, losses, accuracies

```

Funkci zavolejte a natrénujte model. Uvedte zde parametry, které vám dají slušný výsledek. Měli byste dostat přesnost srovnatelnou s generativním klasifikátorem s nastavenými priory. Neměli byste potřebovat víc, než 100 epoch. Vykreslete průběh trénovací loss a validační přesnosti, osu x značte v epochách.

V druhém grafu vykreslete histogramy trénovacích dat a pravděpodobnost třídy 1 pro x od -0.5 do 1.5, podobně jako výše u generativních klasifikátorů.

(1 + 5 + 8 řádků)

```

[89]: disc_fea5, losses, accuracies = train_logistic_regression(100,0.
    ↪001,1,FeatureCutter(FOI))

pass
print('w', disc_fea5.w.item(), 'b', disc_fea5.b.item())

pass
print('disc_fea5:', evaluate(disc_fea5, val_dataset.xs[:, FOI][:, np.newaxis], ↪
    ↪val_dataset.targets))

# Trénovací loss
plt.figure(figsize=(10,5)) # pro lepší citelnost 2 grafu
plt.subplot(1, 2, 1)
plt.plot(range(0,100), losses, label='Trénovací Loss', color='red')
plt.xlabel('Iterace')
plt.ylabel('Loss')
# Validacní přesnost
plt.subplot(1, 2, 2)
plt.plot(range(0,100), accuracies, label='Validacní přesnost', color='green')
plt.xlabel('Iterace')
plt.ylabel('Přesnost')
plt.show()
#rozhodl jsem se umístit do 2 grafu, kvůli přehlednosti

# Vykreslení histogramů a pravděpodobnosti třídy 1
probs_class1 = disc_fea5.prob_class_1(x_axis[:, np.newaxis])

plt.hist(train_dataset.pos[:, FOI], density=True, color='green', alpha=0.7, ↪
    ↪edgecolor='black', linewidth=0.6, label='Pozitivní')


```

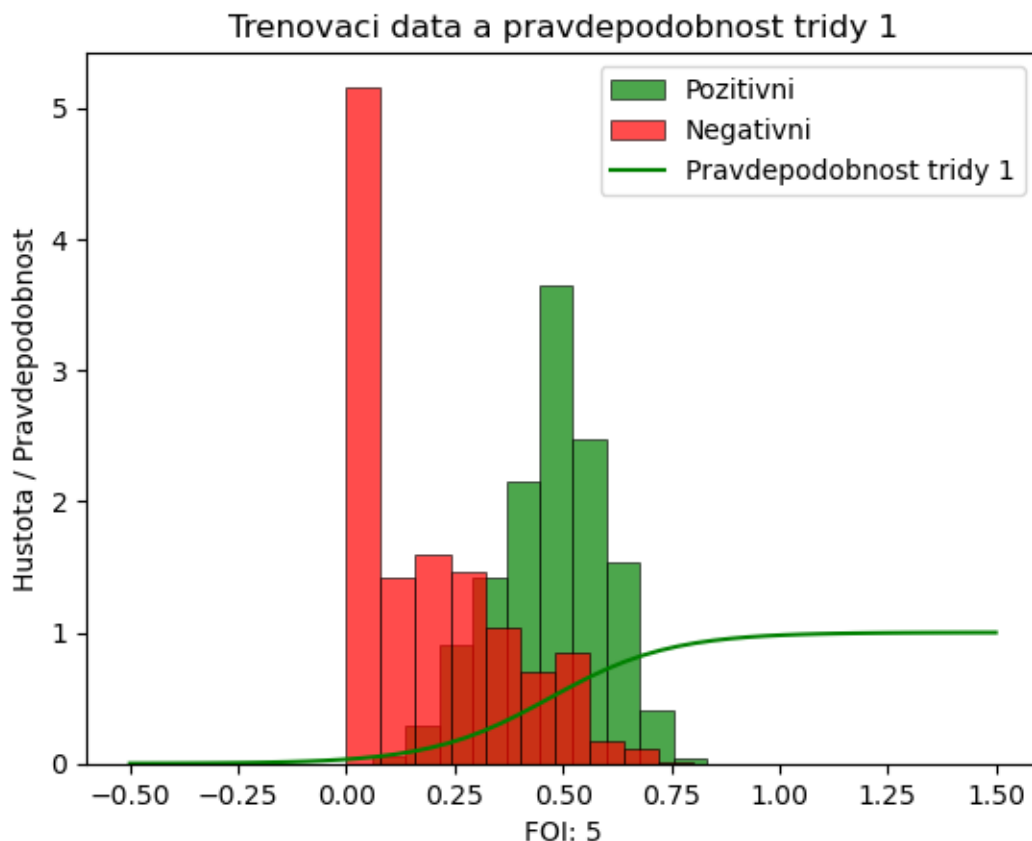
```
plt.hist(train_dataset.neg[:, FOI], density=True, color='red', alpha=0.7,
         edgecolor='black', linewidth=0.6, label='Negativni')
plt.plot(x_axis, probs_class1, label='Pravdepodobnost tridy 1', color='green',
         linestyle='-')

# Popisky grafu
plt.title('Trenovaci data a pravdepodobnost tridy 1')
plt.xlabel(f'FOI: {FOI}')
plt.ylabel('Hustota / Pravdepodobnost')
plt.legend()

plt.show()
```

w 7.222447064152967 b -3.3949621316355643
disc_fea5: 0.844





3.1 Všechny vstupní příznaky

V posledním cvičení natrénujete logistickou regresi, která využije všech sedm vstupních příznaků. Zavolejte funkci z předchozího cvičení, opět vykreslete průběh trénovací loss a validační přesnosti. Měli byste se dostat nad 90 % přesnosti.

Může se Vám hodit `lambda` funkce.

(1 + 5 řádků)

```
[95]: disc_full_fea, losses, accuracies = train_logistic_regression(100, 0.001, 7,
    ↪ lambda x:x)


# plot trenovací loss a validacni presnost
# trenovací loss a accuracies mi neplotuje nektete hodnoty, evaluace regrese
    ↪ nabyva usak validni? hodnoty

# presnost modelu
print('disc_full_fea:', evaluate(disc_full_fea, val_dataset.xs, val_dataset.
    ↪ targets))
```

```

/tmp/ipykernel_5175/1103715093.py:5: RuntimeWarning: divide by zero encountered
in log
    return np.sum(-targets * np.log(probs) - (1-targets)*np.log(1-probs))
/tmp/ipykernel_5175/1103715093.py:5: RuntimeWarning: invalid value encountered
in multiply
    return np.sum(-targets * np.log(probs) - (1-targets)*np.log(1-probs))

```



disc_full_fea: 0.9195

4 Závěrem

Konečně vyhodnoťte všech pět vytvořených klasifikátorů na testovacích datech. Stačí doplnit jejich názvy a předat jim odpovídající příznaky. Nezapomeňte, že u logistické regrese musíte zopakovat formátovací krok z `FeatureCutteru`.

```

[92]: xs_full = test_dataset.xs
      xs_foi = test_dataset.xs[:, FOI]
      targets = test_dataset.targets

      print('Baseline:', evaluate(baseline, xs_foi, targets))

```

```

print('Generative classifier (w/o prior):', evaluate(classifier_flat_prior,
↳xs_foi, targets))
print('Generative classifier (correct):', evaluate(classifier_full_prior,
↳xs_foi, targets))
print('Logistic regression:', evaluate(disc_fea5, xs_foi[:, np.newaxis],
↳targets))
print('logistic regression all features:', evaluate(disc_full_fea, xs_full,
↳targets))

```

Baseline: 0.75

Generative classifier (w/o prior): 0.8

Generative classifier (correct): 0.847

Logistic regression: 0.853

logistic regression all features: 0.922

Blahopřejeme ke zvládnutí projektu! Nezapomeňte (1) spustit celý notebook načisto (Kernel - > Restart & Run all), (2) zkontrolovat, že všechny výpočty prošly podle očekávání, a (3) před odevzdáním pojmenovat soubory loginem vedoucího týmu.

Mimochodem, vstupní data nejsou synteticky generovaná. Nasbírali jsme je z baseline řešení historicky prvního SUI projektu; vaše klasifikátory v tomto projektu predikují, že daný hráč vyhraje dicewars, takže by se daly použít jako heuristika pro ohodnocování listových uzlů ve stavovém prostoru hry. Pro představu, data jsou z pozic pět kol před koncem partie pro daného hráče. Poskytnuté příznaky popisují globální charakteristiky stavu hry jako je například poměr délky hranic předmětného hráče k ostatním hranicím. Nejeden projekt v ročníku 2020 realizoval požadované “strojové učení” v agentovi hrajícím dicewars kopii domácí úlohy, která byla předchůdkyní tohoto projektu.

[]: